



MSGSÜ
FEN-EDEBİYAT FAKÜLTESİ
İSTATİSTİK BÖLÜMÜ
YAPAY SİNİR AĞLARI PROJE ÖDEVİ

Ataman Önel Ük – 20201101058
H.Simay Özgöl – 20201101061

Temmuz 2024

ResNet Tabanlı SVM Kullanarak Radyografi İle Göğüste Etkili Pnömoni Tespiti

Marwa M. Eid and Yasser H. Elawady

Özet

Muayene araçları arasında en temel olarak bilinen göğüs radyografisinin tıbbi görüntüleme tanısı alanında önemli bir yeri vardır. İnsanın akciğer bölgesini hızla etkileyen Pnömoni (Zatürre), yaygın bir enfeksiyon olarak bilinmektedir. Bu rahatsızlığın tespiti için gelişmiş bir yöntem bulmak özellikle gelişmekte olan ülkeler açısından hala çok pahalı olarak görülmektedir. Bu makale, yenilikçi bir yaklaşım ile hesaplamalı yöntemler kullanılarak Pnömoni rahatsızlığının göğüs röntgeni ile tespitinin yapılabilmesi ve bu sayede tek görüntü incelemesi talebi ile maliyetin önemli ölçüde azaltılması konusunu esas almaktadır. Derin öğrenmedeki son gelişmeler ile birlikte farklı alanlardaki görüntü sınıflandırması, dikkate değer ölçüde sonuçlar elde etmiştir ancak ne yazık ki Pnömoni tanısı için durumun kısıtlı olduğu söylenebilir. Bu nedenle, asıl odak noktası bu hastalığı tespit etme alanının geliştirilmesi yönünde bir inceleme yapılması ve önceden eğitilmiş yapay sinir ağlarının (CNN) uygulamalarına öneri sunmak olacaktır. Önerimiz, hiyerarşik özellikleri göze çarpan biçimde seçen ve güçlendiren derin artık sinir ağlarının (ResNet) birleştirilmesi ile sınıflandırma için kullanılan vektör makinelerinin (AdaBoost-SVM) desteklenmesidir. Mevcut veri seti üzerinden yapılmış olan performans analizi sonrasında Pnömoni sınıflandırmasında tanıtılan şemanın, en güncel yaklaşımlardan daha üstün olduğu ve bunun klinik sonuçlar açısından büyük bir iyileşme sağlayabileceği sonucuna varılmıştır.

Dizin Terimleri - Derin öğrenme; Evrimsel Sinir Ağı; ResNet; AdaBoost; SVM; Pnömoni.

1.GİRİŞ

Sağlık bilimi için görüntüler (çıktılar) önemli bir yere sahiptir. Özellikle yeterince deneyime sahip olan radyologların bulunmadığı kırsal kesimlerde bu tür araçlar, kritik veya ek bir teşhis talep eden kişileri tarayarak büyük bir yardım sağlayabilmektedir. Medikal görüntüleme erken teşhis ve kişiye özel terapide hayati bir rol oynamaktadır. Özellikle x-ray görüntüler (röntgen), vücuda herhangi bir cerrahi müdahale yapılmaksızın gerçekleştirilecek şekilde tıbbi durumların teşhis edilmesi ve tedavinin net şekilde izlenmesi bakımından hekimlere yardımcı olmaktadır. Vücudun iç kısmını temsil eden bir görüntüyü görüntülemek için vücudun bir kısmının küçük bir dozda iyonlaştırıcı radyasyona maruz bırakılmasını kapsar. Dikkat çekici bir şekilde, pnömoni, sıklıkla hastaneye yatmayı gerektiren ve önemli ölçüde ölüme neden olan en yaygın morbidite nedenlerinden biridir. Halk sağlığını ilgilendiren konularda, enfeksiyonu insan akciğerlerinin bulunduğu bölgelerde hızla yayıldığı için oldukça kritik bir ilgi çekmektedir. Dahası, dünyada en sık rastlanan enfeksiyon türlerinden biri şeklinde kabul edilmektedir. Tedavi ve terapideki büyük gelişmelere rağmen, dünya genelinde her yıl 5 yaşın altında iki milyondan fazla çocuk zatürreden ölmektedir ve bu rakam 5 yaş altı ölümlerin yaklaşık beşte birini oluşturmaktadır [1]. Çocukların en büyük bulaşıcı katili olan zatürrenin 2030 yılına kadar yaklaşık 11 milyon çocuğu öldürmesi beklenmektedir [2]. Ancak bu ciddi hastalığın tespiti, uzman radyologların mevcudiyetine ve erişilebilirliğine bağlı olan teknik açıdan zorlu bir görevdir. Erken teşhis ve tanı için pnömoninin insan akciğeri üzerindeki etkisini analiz eden az sayıda çalışma olduğu kaydedilmiştir.

Tıbbi görüntüler, araştırma için önemli olabilecek ince özelliklerle doludur. CAD sistemlerinde genellikle birkaç işlem vardır: ön işleme, İlgi Bölgesinin (ROI) izole edilmesi, özelliklerin çıkarılması ve hastalığın bu özelliklere göre sınıflandırılması. Düzenli olarak, ROI bölgelerini vurgulamak, göze çarpan özellikleri çıkarmak ve ilgili gürültüleri bastırmak için çeşitli yöntemler vardır. Kural tabanlı yaklaşımlar zayıf performansla sahiptir ve genellikle sınıflandırma doğruluğunu artırmak için birleştirilirler. Özelliklerin çıkarılması bakımından geometrik özellikler, şekil, doku veya boyutluluğu ve özellik fazlalığını azaltmak için düzenli olarak işlenen el yapımı gibi geleneksel tekniklerle elde edilen özellikler, sınıflandırma performansını etkileyen hatalara sahip olabilir. Bu nedenle, özellik çıkarma aşaması ve iyileştirme ve segmentasyon teknikleri çok kritiktir. Üstelik derin CNN'ler, tıbbi

görüntü sınıflandırma görevleri söz konusu olduğunda doğal başvuru sahiplerini destekleyen ayırt edici özelliklere sahiptir. Önceden eğitilmiş ağlar, karın röntgenleri gibi birçok belirgin farklılığa sahip görüntüleri sınıflandırmada oldukça iyi performans göstermekte olup, [3] yalnızca yeterli miktarda eğitim veri setine ihtiyaç duymaktadır. Önceden eğitilmiş ağlar tıbbi görüntü sınıflandırma görevlerine uygulandığında, yeterli ölçüde iyi bir sonuç elde etmek için daha büyük bir veri kümesi ile daha pahalı eğitim aşamalarına ihtiyaç duyabilirler. Bu gibi durumlarda önceden eğitilmiş ağların sınıflandırıcı olacak şekilde kullanılması, CAD teşhis görevlerinde CNN'lerin kullanılması için çoğunlukla tercih edilen bir yöntem değildir. DCNN'ler gibi önceden eğitilmiş ağlar kullanıldığında, Pnömoni varlığı veya yokluğu gibi ekstra zor veri kümeleri iyi görünmemiştir. Bu nedenle, daha fazla eğitim örneği ve veri seti artırımı verimliliği çoğaltabilir. [4]. CNN tabanlı tanımlama sistemleri çeşitli alanlarda daha yüksek doğruluk sunarken, bu yaklaşımın en büyük dezavantajı, çok fazla eğitim veri kümesi ile aşırı işlem süresi alan daha yoğun bir eğitime ihtiyacı duymasındır.

Bu makalede, bir 50-katmanının son evrimsel katmanından çıkarılan özelliklerin benimsenmesinden türetilen x-ray görüntü temsillerinin ayırt etme gücünü araştırmaktayız. DNN'ler, zor öğrenmeye neden olan kaybolan gradyanlara karşı duyarlıdır. Özellikle ResNet, bilgiyi katmanlar arasında yaymak için atlama bağlantılarını kullanır ve bu, verilerin daha derin ağlar oluşturmaya olanak tanır. Bağlantıların atlanması, ağın genel özellikleri anlamasına ve göğüs röntgeni görüntüsündeki daha küçük nesneleri tespit etmesine yardımcı olur. Dolayısıyla, bir özellik çıkarıcı modül olarak önerilen ResNet sayesinde, ek katmanların istiflenmesi daha derin bir ağ oluşturabilir. Böylece, kaybolan gradyanı dengeleyebilir ve katmanlarını eğitim aşaması boyunca daha az alakalı olacak biçimde şekillendirebilir. Çıkarılan özellik vektörlerinin boyutu büyük olduğundan, boyutluluğu azaltmak için AdaBoost kullanıldığını öneriyoruz. Bu nedenle, ResFeats'in verimliliğini son teknoloji ürünü tanımlama doğruluklarıyla teyit etmek için sonuçlar sunulmuştur. AdaBoost sadece özelliklerin çıkarılmasında değil, aynı zamanda özelliklerin seçilmesinde de umut verici ve tatmin edici bir başarı sağlamaktadır. Dahası, yapay zeka sistemlerinde gerçek zamanlı otomatik insan-bilgisayar etkileşimine basitçe uygulanabilir olması da ek bir kazançtır. Derin öğrenmenin özellik çıkarma veya sınıflandırma konusundaki mükemmel başarısıyla, önerilen derin öğrenme tabanlı yaklaşımlar sürekli olarak harika bir çözüm haline gelmiştir. Sunulan model yüksek varyansa ve düşük yanılğıya sahip olduğundan, sınıflandırıcının araştırma süreci için daha düşük EER'ye ulaşmasını sağlayabilir. Böylece, ResFeats'in hazır eğitilmiş CNN yapıları (VGG 19, AlexNet ve GoogLeNet) ve diğer CNN tabanlı olmayan yöntemlerle karşılaştırıldığında üstün bir tanımlama doğruluğu elde ettiğini doğruluyoruz. Bu, doktorların tedavi alanını belirleme kabiliyetini geliştirir ve iş yükünü azaltmak için radyoloğa büyük destek verir.

Bu makalenin geri kalanı şu şekilde düzenlenmiştir; Bölüm II ilgili çalışmaları özetlemektedir. Bölüm III'te deneyde kullanılan malzeme ve yöntemler açıklanmaktadır. Bölüm IV kullandığımız önerilen sistemi açıklamaktadır. Bölüm V, elde edilen sonuçların tartışmasını sunmaktadır. Son olarak, Bölüm VI, bildiride sunulan çalışmanın sonuçlarını tanıtmaktadır.

2. İLGİLİ ÇALIŞMA

Günümüzde, büyük veri kümelerinin erişilebilirliği ve derin öğrenme modellerindeki en son gelişmeler; kanserin sınıflandırılması [5], [6], kanamanın tanımlanması [7], aritmi tespiti [8] ve diyabetik retinopatinin tespiti [9] gibi çeşitli tıbbi görüntüleme görevlerinde tıbbi personeli alt edebilecek şekilde güç destekli algoritmalarla sahip olunmasına yol açmıştır.

Radyografiler aracılığıyla göğüs hastalıklarının otomatik teşhisi büyük ilgi ve dikkat çekmiştir. Bu yaklaşımlar akciğer nodülünü tespit etmek [10] ve akciğer tüberkülozunu sınıflandırmak [11] için giderek daha fazla kullanılmaktadır. Çeşitli derin evrimsel ağ modellerinin OpenI veri kümesinde bulunan farklı anormallikler üzerindeki performansı, [12] tüm anormalliklerde iyi performans göstermez [13]. Topluluk modelleri tek modelle karşılaştırıldığında sınıflandırma doğruluğunu önemli ölçüde artırır ve son olarak, derin öğrenme yöntemlerinin kullanılması, kural tabanlı yöntemlerin kullanılmasından ziyade sınıflandırma doğruluğunu artırmıştır.

Çok Etiketli Hastalık Sınıflandırması (MDC) arasında istatistiksel bağımlılık incelenmiş, böylece tahminlerin doğruluk seviyeleri elde edilmiştir [14]-[16]. X-ışını görüntülerinden hastalıkların tespiti [17]-[19]'da gerçekleştirilmiştir, göğüs röntgeninden görüntü sınıflandırmaları [20]'de ve göğüs röntgeni ile bilgisayarlı tomografi görüntülerinden vücut parçaları bölütlemesi (Image Segmentation) [5] [17]'de gerçekleştirilmiştir. Aksine, görüntü seçimlerini öğrenmek ve birinin tanımlayacağı şeye göre görüntü tanımları geliştirmek kullanılmalıdır.

Göğüs röntgeni görüntülerinin analizi için derin öğrenme tekniklerini kullanan uygulamalara genel bir bakış Tablo I'de listelenmiştir [21].

TABLE I: OVERVIEW OF APPLICATIONS THAT USE DEEP LEARNING TECHNIQUES FOR THE CHEST X-RAY IMAGES ANALYSIS [21]

Application	Remarks
Detection of Nodule	Classification with CNN two-layer, each with 125×5 filters.
Retrieval of Image	Combination of classical features with pre-trained CNN features for retrieval of image by using SVM.
Detection of Pathology	Take features from a pre-trained CNN and detect various diseases from a low level features.
Retrieval of Image	Continuation of Anvi adding features of age and gender
Detection of Pathology	Continuation of Bar, adding more experiments and feature selection.
Detection of Pathology	Detecting five common abnormalities, validated and trained on a big-data set using GoogLeNet CNN
Detection of Tuberculosis	Using 6 convolution layers pre-trained fine-tuned network to process entire radiographs.
Detection of Tuberculosis	Producing heat map of suspicious regions via de-convolution using MIL framework.
Detection of Pathology	Using huge data set (seven k images), frequent networks produce short captions, and CNN detects seventeen diseases.
classification of Frontal/lateral	Classification of Frontal/lateral using Pre-trained CNN.
Bone suppression	Using cascaded CNNs at high resolution to learn bone images from radiographs.
Nodule classification	Combination of CNN features and classical features from a pre-trained ImageNet CNN.

Yakın tarihli birkaç makale, göğüs röntgeni görüntülerinden pnömoniyi tespit etmek için otomatik bir sistem sunmuştur. Yuan Tian tarafından 2017 yılında kullanılan derin öğrenme [22], göğüs röntgeni görüntülerini analiz ederek pnömoniyi tespit etmek için bir yapay zeka algoritması eğitmek amacıyla kullanılmıştır. CNN sınıflandırıcısı %91'lik bir doğruluk elde etmiştir. Okeke Stephen ve arkadaşları tarafından 2019'da [5] tanıtılmış olan önerilen CNN modeli, göğüs röntgeni görüntülerinden özellikler çıkararak pnömoniyi tespit etmek için oluşturulmuştur. CNN modelinin doğrulama ve sınıflandırma doğruluğunu artırmak için çeşitli veri artırma algoritmaları kullanmışlardır. Sınıflandırıcı %95,31'lik bir doğruluk elde etmiştir.

3. MATERYALLER VE YÖNTEMLER

Bu makalede, önceden eğitilmiş CNN'lerin Pnömoni tespitinde uygulanması için bir öneri sunulacaktır. Bu nedenle, CNN modelleri aracılığıyla hastalıkların teşhisi için yeni bir paradigmaya ihtiyaç duyulabilir. Bu durumda, bu görevi yerine getirmek adına daha uygun bir yol elde etmek için çoklu örnek öğrenme (MIL) rutini ile birlikte daha üstün bir sonuç elde edebilir. En iyi sınıflandırıcının seçilmesi açısından, geleneksel algoritmalarından destek vektör makinesinin (SVM) performansı daha faydalı olabilir.

Derin bir katman yapısına sahip olan CNN kullanılarak Pnömoni hastalığı görüntülerinin sınıflandırılması için bir yöntem önerilmiştir. Öneride, yeniden boyutlandırılmış bir radyografik göğüs görüntüsünden özellikler çıkarmak için bir CNN mimarisi kullanılmaktadır. Daha sonra, önceden eğitilmiş bir ağ tarafından önceden çıkarılan özellikler, yeni bir paradigmaya ulaşmak için güçlü bir sınıflandırıcıyı eğitmek amacıyla kullanılacaktır.

Bu makaledeki tüm deneyler, Core i5 işlemci M520 (Intel Corporation) ve 64 bit işletim sistemi ile donatılmış 4 GB dahili çalışma belleğine sahip bir DELL LATITUDE E6410 kişisel bilgisayarda yüklü Windows 10 (Microsoft Corporation) altında gerçekleştirilmiştir.


• Veri Seti

Bu makalede *Kaggle* veri kümesi Göğüs röntgeni Görüntüleri (Pnömoni) [23] kullanılmıştır. Veri kümesi (JPEG) formatında 5.863 röntgen görüntüsünden oluşmaktadır. *Pnömoni* veya *Normal* olarak iki durumda kategorize edilmiştir. *Kaggle* veri seti, birçok araştırmada küresel olarak kullanıldığı ve bilimsel araştırmaları zenginleştiren iyi bir karşılaştırma yapabildiği için bu makalede kullanılmak üzere seçilmiştir.

Şekil 1'de Pnömoni olmayan normal görüntü örnekleri, Şekil 2'de ise Pnömoni olan görüntü örnekleri gösterilmektedir.



Şekil 1. Pnömoni olmayan normal görüntüler için bir örnek.



Şekil 2. Pnömonili görüntüler için bir örnek.

• Evrimsel Sinir Ağı (CNN)

CNN, görüntü analizinde uzmanlaşmış ve hastalıkların tespitinde önceki yöntemlerden daha yüksek doğruluk elde eden bir derin sinir ağıdır (DNN) türüdür. Bu nedenle, kümeleme, nesne algılama ve görüntü sınıflandırma gibi bilgisayarla görme uygulamalarında yaygın olarak kullanılmaktadır.


Aşağıdaki bölümde AlexNet [24], [25], VGG-Net [26], GoogLeNet [27] ve ResNet [28] gibi çeşitli CNN modelleri özetlenmektedir. Bu modellerde farklı sayıda konvolüsyon katmanı kullanılmaktadır. CNN modellerinde, konvolüsyon katmanlarının sayısı arttıkça daha yüksek sınıflandırma doğruluğu elde edilmektedir.

AlexNet [25]: Krizhevsky AlexNet'i ilk kez 2012 yılında önermiş ve bu yıl ImageNet Büyük Ölçekli Görsel Tanıma Yarışması olan (ILSVRC) [28]'i kazanmıştır. Üç tam bağlı katman ve beş evrimsel katmandan oluşmaktadır.

VGGNet [26]: VGGNet, 2014 yılında ILSVRC yarışmasını yerleştirme ve sınıflandırma dallarında kazanmıştır. Sahip olduğu iki popüler mimari: VGGNet-19 ve VGGNet-16. Geniş bir yelpazede basit bir kullanım şekline sahiptir. Üç tam bağlantılı katmana, beş havuzlama katmanına ve 13 evrimsel katmana sahiptir.

GoogLeNet [27]: CNN mimarisinin başka bir modelidir. İki ana avantajı vardır. Birincisi, GoogLeNet aynı katmanda farklı boyutlarda filtre çekirdekleri kullanmıştır. İkincisi; daha az sayıda ağ parametresi kullanır, bu da daha derin olmasını sağlar ve aşırı uyuma karşı daha az hassas olmasını sağlar. Son olarak, GoogLeNet, AlexNet'ten on iki kat daha az parametreye sahiptir.

ResNet (Artık Ağ) [28]: CNN'lerin en verimli modellerinden biridir. Bilgisayarla Görme ve Örnekleme Tanıma Konferansı'nda (2016) *ResNet*, en iyi bildiri olarak ilan edilmiştir. *ResNet* fikri, her katmanın tüm özellik uzayı dönüşümünü değil, yalnızca bir önceki katmanın artık düzeltilmesini öğrenmesi gerektiğidir, bu da verimli çalışan daha derin bir ağ eğitimi sağlar. Şekil 3, *ResNets*'in üzerine inşa edildiği artık blokları göstermektedir. *ResNets*'in ana fikri (1) katmanının aktivasyonunu (1+2) katmanının çıkışına eklemektir ki buna kimlik kısayol bağlantısı denir [22]. *ResNet*, gradyan kaybolması ve patlaması sorunlarından muzdarip olmadan çok daha derin sinir ağlarını eğitmeyi sağlar. Bu makalede, ImageNet sınıflandırma veri kümesi üzerinde önceden eğitilmiş *ResNet50*'yi kullanacağız.



• Uyarlanabilir Boosting (AdaBoost) Algoritması

Yoav Freund ve Robert Shapire 1995 yılında AdaBoost algoritmasını önermiştir [29]. Algoritma, bir dizi zayıf öğrenici oluşturmak için eğitim verileri üzerinde bir ağırlık koleksiyonu tutar ve her zayıf öğrenme döngüsünden sonra bunları uyarlamalı olarak ayarlar. Doğru sınıflandırılan eğitim örneklerinin ağırlıkları azaltılırken, mevcut zayıf öğrenici tarafından yanlış sınıflandırılanların ağırlıkları artırılır [29]. AdaBoost algoritmasının avantajları:

- Hızlı yakınsama.
- Makine öğrenimi algoritması tarafından uygulanması kolaydır.
- Zayıf öğrenci hakkında herhangi bir ön bilgi gerektirmez.
- Zayıf hipotezleri bulmak için destek vektör makinesi gibi diğer algoritmalarla kolayca birleştirilebilir.

Birçok uygulamada, AdaBoost algoritması bir sınıflandırıcı ve özellik seçimi veya çıkarımı olarak kullanılabilir. Bu makalede AdaBoost algoritması özellik seçimi olarak kullanılmıştır.

• Destek Vektör Makinesi (SVM) Sınıflandırıcısı

Vapnik, Yapısal Risk Minimizasyonu teorisinden DVM'yi [29] geliştirmiştir. DVM, denetimli bir makine öğrenme algoritması olarak kabul edilir ve birçok sınıflandırma probleminin çözümünde kullanılır. Ayrıca, verileri dönüştüren ve bu dönüşümlere göre olası çıktılar arasındaki en uygun sınırı bulan bir ikili sınıflandırma algoritması olarak bilinir, bu teknik çekirdek hilesi olarak adlandırılır. Doğrusal olmayan DVM, algoritmanın hesapladığı sınırın düz bir çizgi olmak zorunda olmadığı anlamına gelir. Bu faydalıdır çünkü karmaşık dönüşümleri kendiniz yapmak zorunda kalmazsınız ve veri noktalarınız arasında daha karmaşık olan birçok ilişkiyi yakalayabilirsiniz.

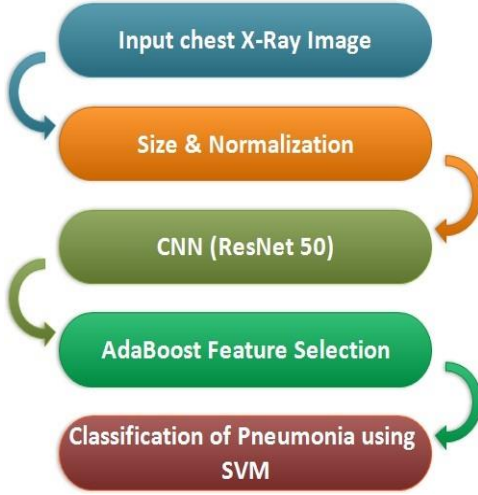
DVM'ler aşağıdaki nedenlerden dolayı önemlidir [29]:

Çok fazla sayıda değişken ve küçük örneklemeler olması durumunda güçlüdür.

Hem basit hem de oldukça karmaşık sınıflandırma modelleri öğrenilebilir.

Birçok araştırmacı, gerçek DVM'nin sınıflandırma performansını iyileştirmek için geleneksel Bagging ve AdaBoost [29] gibi topluluk yöntemlerini kullanmaya çalışmaktadır. Son olarak, ancak daha da önemlisi, DVM kararlı ve güçlü bir sınıflandırıcı olarak bilinir.

4. ÖNERİLEN SİSTEM



Önerilen sistemde uygulanan prosedüre genel bir bakış yandaki şemada gösterilmektedir.

4.1. Derin Artık CNN'lerin Yapısı

ResNet-50 modeli [30]-[32], tam bağlı katmandaki düğümleri değiştirerek ve deneysel veri kümesini kullanarak ince ayar işlemini gerçekleştirerek göğüs röntgeni görüntülerinden göze çarpan özellikleri çıkarmak için uyarlanmıştır. Ayrıca ResNet-50 modelini ince ayar boyunca uygularken; giriş her görüntü için 224×224 piksele yeniden boyutlandırılmalıdır [33]. Bu nedenle, önerilen sistemde orijinal görüntülerin boyutu Şekil 5 ve Tablo II'de tanıtıldığı gibi önerilen yapıya uygun olacak şekilde değiştirilmiştir. Ayrıca, bu ön aşamalardan sonra (yani, yeniden boyutlandırma ve sıfır merkezli normalleştirme), oluşturulan görüntü önerilen CNN için nihai girdi olarak kullanılır.

Benimsenen CNN'in katman ve filtre sayısına ilişkin yapısı ve özellikleri, çıkış FC katmanındaki düğüm sayısı dışında [33]'teki ResNet-50 CNN modeliyle aynı seçilmiştir. Bu araştırma iki kategoriyi sınıflandırmaya odaklanmaktadır. Bu nedenle FC katmanındaki çıkış düğümleri iki olarak ayarlanmıştır (Pnömoni veya Normal).

Tablo II'de evrimsel katmanların temel özelliklerisunulmuştur.

Özellik çıkarma adımında, havuzlama veya alt örnekleme katmanları (Max pool ve AVG pool) göze çarpan özellikleri elde etmek için maksimum ve ortalama piksel değerlerini seçer [33], [34]. Tablo II'den, evrimsel katmanlar (Conv1~Conv5) şeklindedir.

Şekil 5'te gösterildiği gibi, Conv3 ~ Conv5, kendisinden önceki ve sonraki kanalların boyutunun sırasıyla 256 ve 512 olduğu bir darboğaz yapısına sahiptir. Daha sonra, pratik hususlar ve konvolüsyon işlemi sırasında hesaplamalarda daha verimli olması için, $(3 \times 3 \times 128)$ boyutundaki filtreler tarafından 128'e indirilirler. Tablo II'deki iterasyon sayısına bağlı olarak katmanlar (Conv2 ~ Conv5), ardışık olarak çalışmak için iterasyona tabi tutulur.

Ayrıca, Conv2-1, Conv3-1, Conv4-1 ve Conv5-1'den önceki özellikler haritasındaki tutma verileri, Şekil 5'te gösterildiği gibi alternatif katman üzerinden çıkış haritalarına (yani Conv2-3 ~ Conv5-3) ayrı ayrı toplanır. Tablo II, ResNet-50 yapısının derin ayrıntılarını göstermektedir. Tablo II'de, "3*" girdinin bu konumlarında (sol, sağ, yukarı ve aşağı) 3 pikselin dolgu işlemine dahil edildiğini gösterirken, "1*" ise solda 1 pikselin yer aldığını, "2/1*" ilk iterasyonda ise 2 ve ikinci iterasyondan itibaren 1 olduğunu belirtir. Dolayısıyla, ResNet-50 yapısı, her evrimsel katmandan sonra toplu normalizasyon [35] işlemini uygulayarak ve ardından bir aktivasyon fonksiyonu olarak ReLU [36] kullanarak daha doğru filtreler ve sınıflandırıcılar tutabilir.

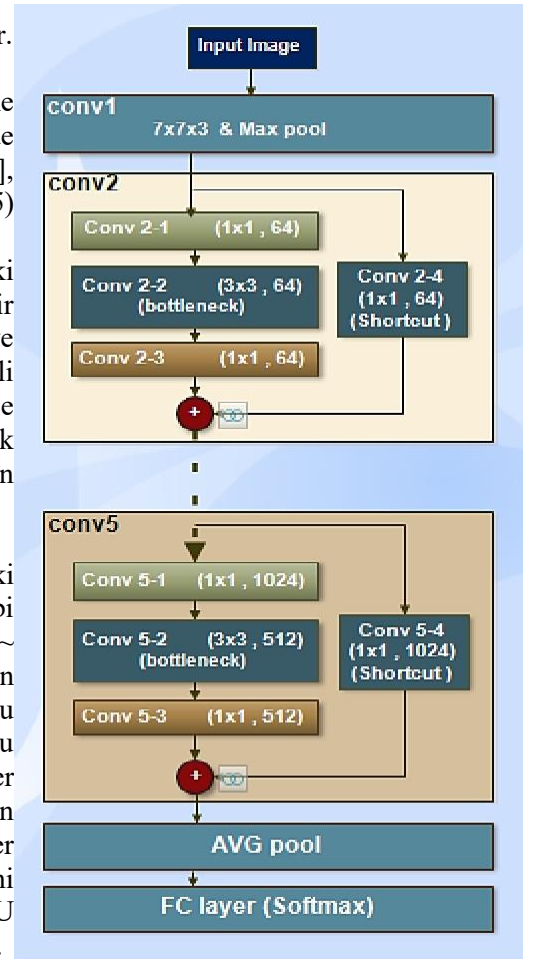


TABLE II: CONVOLUTION LAYERS DATA OF THE IMAGE						
No. of iterations	Padding Amount	No. of strides	Filter Size	Filters No.	The feature map size	Layer
1	3*	2	7 x 7 x 3	64	224 x 224	input layer
1	0	2	3 x 3	1	112 x 112	Conv 1
3	0	1	1 x 1 x 64	64	56 x 56	Max pool
	1*	1	3 x 3 x 64	64	56 x 56	Conv2-1
	0	1	1 x 1 x 64	256	56 x 56	Conv2-2
						Conv2-3
	0	1	1 x 1 x 64	256	56 x 56	Conv2-4
						(shortcut)
4	0	2/1**	1 x 1 x 256	128	28 x 28	Conv3-1
	1*	1	3 x 3 x 128	128	28 x 28	Conv3-2
	0	1	1 x 1 x 128	512	28 x 28	(Bottleneck)
	0	2	1 x 1 x 256	512	28 x 28	Conv3-3
						Conv3-4
						(shortcut)
6	0	2/1**	1 x 1 x 512	256	14 x 14	Conv4-1
	1*	1	3 x 3 x 256	256	14 x 14	Conv4-2
	0	1	1 x 1 x 256	1024	14 x 14	(Bottleneck)
	0	2	1 x 1 x 512	1024	14 x 14	Conv4-3
						Conv4-4
						(shortcut)
3	0	2/1**	1 x 1 x 1024	512	7 x 7	Conv5-1
	1*	1	3 x 3 x 512	512	7 x 7	Conv5-2
	0	1	1 x 1 x 512	2048	7 x 7	(Bottleneck)
	0	2	1 x 1 x 1024	2048	7 x 7	Conv5-3
						Conv5-4
						(shortcut)
1	0	1	7 x 7	1	1 x 1 x 2048	AVG pool
1					2	FC layer
1					2	softmax

B. Evrişimsel Katman¹lar Aracılığıyla Özellik Çıkarımı

Her görüntüye tipik bir 2D konvolüsyon prosedürü uygulayarak, göze çarpan özellikler çıkarılabilir. Ayrıca bir görüntüde dikkate alınacak alan, dahil edilen her filtrenin boyutuna bağlı olarak değişir. Ayrıca, dolgu seçeneklerine bağlı olarak, filtre araştırması ve elde edilen görüntülerin hem yüksekliği hem de genişliği değişmektedir [36]. Bu nedenle, dikkate alınması gereken temel faktörler filtre sayısı, filtre boyutları, adımlar ve dolgu seçenekleridir. Tablo II'de gösterildiği gibi, Conv1 (7×7×3) filtre boyutunda 64 filtreden oluşur ve iki pikselden oluşan bir birim tarafından adımlanırken her iki yönde de araştırma yapar. Ayrıca, dolgu işlemi her yöne üç piksellik bir birimde kullanılır. Max havuzu ise dikey ve yatay piksellerin yönlerini araştırmak için tek bir (3×3) filtreden oluşur ve 2 piksellik bir birim tarafından adımlanır. Tablo II'de gösterildiği gibi, Conv2-1 konvolüsyon işlemini boyutları (1×1×64) olan, her yönde ve adımda tek bir piksel birimi tarafından araştırılan 64 filtre ile verir. Ayrıca Conv2-2, her yönde araştırma yapan ve tek bir piksel dolgu ile 1 piksel birim adım atan (3×3×64) filtrelerle konvolüsyon işlemini yapar. (Conv2 ~ Conv5) içinde, elde edilen özellikler Şekil 5'te gösterildiği gibi iki kategoridedir. İlki, sıralı olarak çalışan evrişimsel katmanlardır (Conv2 ~ Conv5). İkinci kategori ise (Conv2-1 ~ Conv5-)'in önündeki özellikler haritasındaki artık bilgidir.

Buna ek olarak, Şekil 5 ve Tablo II'de gösterildiği gibi çıkış haritası (Conv2-3 ~ Conv5-3) içindeki kısayol katmanına gömülen eleman bazlı özelliklerdir. Ayrıca, 1x1 durumunda olduğu gibi daha küçük filtre boyutu uygulanarak, eğitim işleminde talep edilen filtre parametreleri önemli ölçüde azaltılır.


Tablo II'de gösterildiği gibi Conv-1'den (FC katmanı) her bir katman üzerinde ince ayar yapılmıştır. Ayrıca, ayrı evrişimsel katmanı takiben, hesaplanan ortalama değere ve standart sapmanın sonucuna bağlı olarak tüm verilere toplu normalleştirme gerçekleştirilir. Buna ek olarak, aktivasyon fonksiyonu (ReLU) her toplu normalleştirme prosedürünü takip eder. ReLU katmanında belirli bir girdi için sonucu elde etmek için kullanılan süreç (1)'deki gibidir:

$$z = \max(0; y) \quad (1)$$

Burada y, ReLU giriş fonksiyonudur ve z, çıkışın değeridir.

Denklem 1 uygulanarak, z aralıkları sıfıra veya küçük pozitif değerlere indirgenebilir, bu da CNN modeline daha kolay eğitim kazandırabilir. Ayrıca, y değişkenine pozitif değer verilmesi durumunda, z çıkışı da y 'ye benzer ve birinci dereceden türev birdir. Bu da eğitim matematiksel denklemi için daha yönetilebilirdir. Basitçe bu denklem, geriye yayılımda öğrenmede sigmoid fonksiyonun veya hiperbolik tanjantın kullanılmasında ortaya çıkan kaybolma gradyanı [37] sorunlarını sınırlandırabilir.

Ayrıca hesaplama süresinde doğrusal olmayan aktivasyon fonksiyonunu aşar. Böylece öğrenme verimliliği tamamen yükselir çünkü öğrenmede geçen süre azalmaktadır. Conv5 ile ilgili olarak, tek piksellik bir adımla 7×7 filtrenin kullanıldığı AVG havuz katmanı uygulanmıştır. Bu nedenle, Çıkarılan özellik haritasının bir sonraki adıma girdi olarak aktarılacağı değer $(1 \times 1 \times 2048)$ 'dir. Bu makalede kullanılan farklı Derin Evrimsel Sinir Ağları (DCNN'ler) türlerinin sınıflandırma teknikleri şekil 6'da görselleştirilmiştir.



5. SONUÇLAR VE TARTIŞMA

Veri kümeleri için, görüntüler rastgele bir şekilde (%60) eğitim, (%20) doğrulama ve (%20) test aşamasını uygulamak için görüntülere ayrılmıştır. Eğitim verileri ağı eğitmek için kullanılırken, doğrulama verileri model seçimi için ve test verileri de öngörülemez durumlarda model verimliliğini değerlendirmek için kullanılmıştır. Performansı değerlendirmek için geçen süre, doğruluk, hassasiyet, yanlış pozitif oranı, kesinlik ve F-skoru gibi çeşitli performans ölçütleri hesaplanmıştır. Bu metrikler aşağıdaki gibi tanımlanabilir:

Doğruluk [39]: Bir tahmin edicinin, pozitif olmasına bakılmaksızın tüm örnekleri doğru bir şekilde tanımlama yeteneğini ölçer ve (2) ile hesaplanır;

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \times 100 \quad (2)$$

Burada, TP gerçek pozitif değeri, FN yanlış negatif değeri, TN gerçek negatif ve FP yanlış pozitif oranıdır.

Hassasiyet (geri çağırma) [39]: gerçek pozitif oranıdır (TPR). (3) ile hesaplanan pozitif örnekleri tanıma kapasitesini hesaplar:

$$TPR = \frac{TP}{TP+FN} \times 100 \quad (3)$$

Özgüllük [39]: Gerçek negatif oranıdır (TNR) ve (4) ile hesaplanan negatif örnekleri bulma yeteneğini alır:

$$TNR = \frac{TN}{TN+FP} \times 100 \quad (4)$$

Yanlış pozitif oran (FPR) [39]: Yanlış pozitif oran, hatalı kısımları ölçen bir değerdir. (5) ile hesaplanır:

$$FPR = \frac{FP}{FP+TN} \times 100 \quad (5)$$

Kesinlik [39]: pozitif tahmin değerini (PPV) ifade eder ve tüm pozitif değerler arasında gerçek pozitiflerin oranını yönlendirir. (6) ile hesaplanır:

$$PPV = \frac{TP}{TP+FP} \times 100 \quad (6)$$


F-skoru [39]: hassasiyet ve duyarlılığın (geri çağırma) harmonik ortalamasını ölçer. (7) ile hesaplanır:

$$F_{Score} = 2 * \frac{PPV*TPR}{PPV+TPR} \times 100 \quad (7)$$

Deneylerden elde edilen Gerçek Pozitif Oranı (TPR), Gerçek Negatif Oranı (TNR), Yanlış Tahmin Oranı (FPR) ve Pozitif Tahmin Değeri (PPV) sonuçları Tablo III'te listelenmiştir.

TANLE III: TPR, TNR, FPR, AND PPV FOR THE DIFFERENT USED CLASSIFICATION METHODS				
Methodology	TPR	TNR	FPR	PPV
<i>AlexNet</i>	90.5473	97.8495	1.9900	97.8495
<i>GoogLeNet</i>	90.1615	91.4394	8.5606	91.5735
<i>Vgg19</i>	74.1294	75.12	0.2488	99.6656
<i>Resnet50 +PCA+SVM</i>	86.6431	89.03	9.0766	91.4243
<i>Resnet50 + (AdaBoost_SVM) (proposed)</i>	96.4029	99.8	0	100

Önerilen yöntemin ROC eğrisi Şekil 7'de gösterilmektedir. Önerilen yöntem, eğri altındaki alanın (AUC) maksimumuna ve %100'e eşit olduğunu göstermektedir.



Deneylerden elde edilen Doğruluk, F_score ve geçen süre sonuçları Tablo IV'te listelenmiştir. Tablo IV'ten, önerilen tekniğin doğruluğunun %98,13 olduğunu ve bu oranın diğer tekniklerle karşılaştırıldığında daha iyi olduğunu görmekteyiz.

TABLE IV: ACCURACY, F_SCORE AND ELAPSED TIME FOR THE DIFFERENT USED CLASSIFICATION TECHNIQUES

Methodology	Accuracy	F-score	Elapsed Time
<i>AlexNet</i>	94.2786	94.0568	176 mins.
<i>GoogLeNet</i>	90.7905	90.8620	340 mins.
<i>Vgg19</i>	86.9403	85.0214	14881.8 mins.
<i>Resnet50 +PCA+SVM</i>	88.6652	88.9695	447.82 sec
<i>Resnet50 + (AdaBoost_SVM)</i>	98.1343	98.1685	208.13 sec
<i>(proposed)</i>			

Tablo V, pnömoni tespiti için önerilen teknik ile diğer araştırmacıların teknikleri arasındaki karşılaştırmayı göstermektedir. **Yuan Tian** bizim kullandığımız veri kümesini kullanmış ve ResNet_34 tekniği ile pnömoniyi tespit etmek için %91 doğruluk oranı vermiştir. **Okeke Stephen** başka bir veri kümesi kullanmış ve kendi teknikleriyle pnömoniyi tespit etmek için %95,31'lik bir doğruluk oranı vermiştir.

TABLE V: A COMPARISON BETWEEN THE PROPOSED TECHNIQUE AND OTHER RESEARCHER'S TECHNIQUES

Method	Data set	Technique	Accuracy
[22]	5,863 chest-x ray images, Kaggle	CNN (ResNet34)	91%
[5]	5,856 chest x-ray images, retrospective pediatric patients, from 1 to 5 years old.	CNN (Own algorithm)	95.31%
Proposed Method	5,863 chest-x ray images from Kaggle	CNN (Resnet50 + Quadratic SVM)	98.13%

6. SONUÇ

Pnömoni, sıklıkla hastaneye yatmayı gerektiren önemli hastalıklardan biri olarak kabul edilmektedir. Göğüs röntgeni görüntülerinden Pnömoniyi tespit etmek için en etkili şemayı bulmak, enfeksiyonu insan akciğerlerini hızla alevlendirdiği için kritik öneme sahiptir. CNN'i eğitmenin zaman alıcı şemasının ve MIL tabanlı yöntemlerin düşük doğruluğunun üstesinden gelmek için, bir (AdaBoost -SVM) sınıflandırıcı ile birlikte derin bir artık CNN yapısı kullanarak Pnömoni hastalığı görüntülerini sınıflandırmak için önerilen şema, ortak ilgili çalışmalar ve geleneksel algoritmalarla karşılaştırıldığında daha yüksek performans ve daha düşük hata oranı sağlamıştır. Farklı CNN yapıları dışında, ResNet'lerin eğitilmesi daha kolaydır. Bununla birlikte, artık derin öğrenme ve ResNets'teki kimlik eşlemelerinin özellik tespitinde olağanüstü sonuçlar elde ettiği gösterilmiştir. Çok derin ağların aşırı uyum ve doygunluk yanlışlığına neden olduğu bilinmektedir. Ancak, ResNet'lerdeki artık öğrenme ve kimlik eşlemelerinin bu sorunların üstesinden geldiği kanıtlanmıştır. Dahası, ResNet özellikleri, sınıflandırma adımına uygulandıklarında onları doğal adaylar haline getiren ayırt edici özelliklere sahiptir. Sadece özelliklerin çıkarılması değil, aynı zamanda özelliklerin seçilmesi de kritiktir. Önerilen AdaBoost tekniği, gerçek zamanlı ve hızlı bir CAD sistemine uyacak şekilde yerine getirilmiş bir başarı sağlar. Simülasyon sonuçlarından, önerdiğimiz özelliklerin güçlü olduğunu ve CNN hazır özelliklerinden daha yüksek bir sınıflandırma doğruluğuna sahip olduğunu teyit ediyoruz. Son olarak, çalışmadaki yaklaşım sayesinde, göğüs röntgeni alanında Pnömoni hastalıklarının etkili bir şekilde araştırılması ve pnömotoraks alanında potansiyel teşhisin doğruluğunun artırılmasını beklemek yanlış olmayacaktır. Genel olarak, gelecekteki çalışmalarımız çok dereceli hastalık teşhisinin tespitini iyileştirmekle ilgili olabilir.

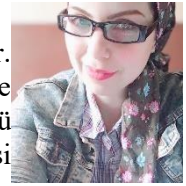
REFERANSLAR

- [1] Lakhani, P., & Sundaram, B. "Göğüs Radyografisinde Derin Öğrenme: Konvolüsyonel Sinir Ağları Kullanılarak Akciğer Tüberkülozunun Otomatik Sınıflandırılması". *Radiology*, 284(2), pp.574–582. 2017.
- [2] Sharma, Raju , A., D., & Ranjan, S. "Görüntü işleme yaklaşımı kullanılarak göğüs röntgeninde pnömoni bulutlarının tespiti". *Uluslararası Mühendislik Konferansı, Nirma Üniversitesi, NUIcone 2017*.
- [3] Lakhani, P. "Endotrakeal Tüp Konumu ve Röntgen Görüntüsü Sınıflandırması için Derin Evrişimli Sinir Ağları: Zorluklar ve Fırsatlar". *Digital Imaging Journal*, 30(4), pp.460-468. 2017.
- [4] City, Q., & Hutchison, D. "Deep Learning in Medical and Multimodal Learning", (Vol. 3). 2017.
- [5] Stephen, O., Maduh, Sain, M., U. J., & Jeong, D. U. "An Efficient Deep Learning Approach to Pneumonia Classification in Healthcare". *healthcare engineering Journal*, 2019.
- [6] Esteva, A., Novoa, Kuprel, B., R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. "Derin sinir ağları ile cilt kanserinin dermatolog düzeyinde sınıflandırılması". *Nature*, 542(7639), 115. 2017.
- [7] Grewal, M., Srivastava, M. M., Kumar, P., & Varadarajan, S. Radnet: "CT taramalarında kanama tespiti için derin öğrenme kullanarak radyolog düzeyinde doğruluk". *IEEE Uluslararası Biyomedikal Görüntüleme Sempozyumu (ISBI)*, pp. 281-284. Nisan 2018.
- [8] Rajpurkar, P., A. Y., Hannun, Haghpahani, M., Bourn, C., & Ng, A. Y. "Konvolüsyonel sinir ağları ile kardiyolog düzeyinde aritmi tespiti". *arxiv :1707.01836.*, 2017.
- [9] Ibrahim, A., El-kenawy, E. S. M. . Süperpiksel Tekniklerine Daya 1 1 Görüntü Bölütleme Yöntemleri: Bir Araştırma. *Bilgisayar Bilimleri ve Bilişim Sistemleri Dergisi*, 15 (3 Ekim 2020). (2020).
- [10] Ibrahim, A., El-kenawy, E. S. M. . Süperpiksel Teknikleri için Uygulamalar ve Veri Kümeleri: Bir Araştırma. *Journal of Computer Science and Information Systems*, 15 (3 Ekim 2020). (2020).

- [11] Lakhani, P., & Sundaram, B. " Göğüs radyografisinde derin öğrenme: konvolüsyonel sinir ağları kullanılarak akciğer tüberkülozunun otomatik sınıflandırılması ". Radiology, 284(2), pp.574-582. 2017.
- [12] El-Kenawy, El-Sayed M., Abdelhameed Ibrahim, Seyedali Mirjalili, Marwa Metwally Eid ve Sherif E. Hussein. "BT görüntülerinde COVID-19 sınıflandırması için yeni özellik seçimi ve oylama sınıflandırıcı algoritmaları." IEEE Access 8 (2020): 179317-179335
- [13] Islam, M. T., Aowal, M. A., Minhaz, A. T., & Ashraf, K. "Abnormality detection and localization in chest x-rays using deep convolutional neural networks". arxiv :1705.09850. 2017.
- [14] Yao, L., Poblens, E., Dagunts, D., Covington, B., Bernard, D., & Lyman, K. " Etiketler arasındaki bağımlılıklardan yararlanarak sıfırdan teşhis koymayı öğrenme ". arxiv :1710.10501.2017.
- [15] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. "Chestx-ray8: Hastane ölçeğinde göğüs röntgeni veritabanı ve yaygın toraks hastalıklarının zayıf denetimli sınıflandırılması ve lokalizasyonu üzerine kıyaslamalar". IEEE bilgisayarla görme ve görüntü tanıma konferansı, s. 2097-2106. 2017.
- [16] Shin, H. C., Lu, L., Kim, L., Seff, A., Yao, J., & Summers, R. M. "Otomatik Görüntü Yorumlama için Büyük Ölçekli Radyoloji Veritabanında Serpiştirilmiş Metin/Görüntü Derin Madenciliği". Journal of Machine Learning Research, 17.pp.1-31, 2. 2016.
- [17] Fouad, Mohamad M., Ali Ibrahim El-Desouky, Rami Al-Hajj, ve El- Sayed M. El-Kenawy. "Dinamik grup tabanlı işbirlikçi optimizasyon algoritması." IEEE Access 8 (2020): 148378-148403.
- [18] Melendez, J., van Ginneken, B., Maduskar, P., Philipsen, R. H., Reither, K., Breuninger, M., & Sánchez, C. I. "A novel multiple- instance learning-based approach to computer-aided detection of tuberculosis on chest x-rays". Tıbbi görüntüleme üzerine IEEE işlemleri, 34(1), pp.179-192. 2014.
- [19] Jaeger, S., Karargyris, A., Candemir, S., Folio, L., Siegelman, J., Callaghan, F., & Thoma, G. "Göğüs radyografileri kullanılarak otomatik tüberküloz taraması". Tıbbi görüntüleme üzerine IEEE işlemleri, 33(2), pp.233-245. 2013.
- [20] Xue, Z., You, D., Candemir, S., Jaeger, S., Antani, S., Long, L. R., & Thoma, G. R. " Göğüs röntgeni görüntü görünümü sınıflandırması". IEEE International Symposium on Computer- Based Medical Systems .pp. 66-71. Haziran, 2015.
- [21] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... & Sánchez, C. I. " Tıbbi görüntü analizinde derin öğrenme üzerine bir araştırma". Tıbbi görüntü analizi, 42, pp.60-88. 2017.
- [22] Hassib, Eslam M., Ali I. El-Desouky, Labib M. Labib ve El-Sayed M. El-kenawy. "WOA+ BRNN: Balina optimizasyonu ve derin sinirağı kullanan dengesiz bir büyük veri sınıflandırma çerçevesi." Soft computing 24, no. 8 (2020): 5573-5592.
- [23] <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>, Han, J., Zhang, D., Cheng, G., Liu, N., & Xu, D. " Belirgin ve kategoriye özgü nesne tespiti için gelişmiş derin öğrenme teknikleri: bir anket ". IEEE Sinyal İşleme Dergisi, 35(1), pp.84-100. 2018.
- [24] El-kenawy, E. S. M. T. "Hemoglobin Tahmini ve Anemi Sınıflandırması için Bir Makine Öğrenimi Modeli." International Journal of Computer Science and Information Security (IJCSIS) 17, no. 2 (2019).
- [25] Simonyan, K., & Zisserman, A. "Büyük ölçekli görüntü tanıma için çok derin evrişimli ağlar". arxiv arxiv:1409.1556. 2014.
- [26] Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., & Rabinovich, A. "Going deeper with convolutions". IEEE bilgisayarla görme ve görüntü tanıma konferansı .pp. 1-9., 2015.
- [27] He, K., Zhang, X., Ren, S., & Sun, J. "Görüntü tanıma için derin artık öğrenme". IEEE bilgisayarla görme ve

- örüntü tanıma konferansı, s. 770-778. 2016.
- [28] Wang, R." Özellik seçimi, sınıflandırma ve SVM ile ilişkisi için AdaBoost, bir inceleme". Physics Procedia, 25, pp.800-807. 2012.
- [29] Jung, H., Choi, M. K., Jung, J., Lee, J. H., Kwon, S., & Jung, W. Y. "Trafik Gözetleme Sistemlerinde ResNet Tabanlı Araç Sınıflandırma ve Lokalizasyon". IEEE Bilgisayarla Görme ve Örüntü Tanıma Çalıştayları Konferansı. pp. 934-940. Temmuz, 2017.
- [30] Zagoruyko, S., & Komodakis, N. "Wide Residual Networks". Arxiv.org adresinden alındı, 2016.
- [31] Mahmood, A., M., Bennamoun, An, S., & Sohel, F. "Resfeats: Görüntü sınıflandırması için artık ağ tabanlı özellikler". Uluslararası Görüntü İşleme Konferansı, ICIP. pp.1597-1601. 2018.
- [32] He, K.; Zhang, X.; Ren, S.; Sun, J. "Görüntü tanıma için derin artık öğrenme". IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, pp. 770-778. Haziran, 2016.
- [33] Lecun, Y.; Bottou, Bengio, L.; Y.; Haffner, P." Belge tanıma için uygulanan gradyan tabanlı öğrenme". Proc. IEEE. 86, pp.2278- 2324. 1998.
- [34] Ioffe, S.; Szegedy, C. "Toplu normalleştirme: Dahili ortak değişken kaymasını azaltarak derin ağ eğitimi hızlandırma". Uluslararası Makine Öğrenimi Konferansı Bildiriler Kitabı, Lille, Fransa, s. 448-456. Temmuz, 2015.
- [35] E.-S. El-Kenawy and M. Eid, "Hybrid gray wolf and particle swarm optimization for feature selection," International Journal of Innovative Computing Information and Control, vol. 16, no. 3, pp. 831-844, 2020.
- [36] Glorot, X.; Bordes, A.; Bengio, Y. "Deep sparse rectifier neural networks". 14. Uluslararası Yapay Zeka ve İstatistik Konferansı, Fort Lauderdale, FL, ABD. pp. 315-323. Nisan, 2011.
- [37] El-Kenawy, El-Sayed M., Marwa Metwally Eid, Mohamed Saber ve Abdelhameed Ibrahim. "MbGWO-SFS: Özellik seçimi için stokastik fraktal aramaya dayalı modifiye ikili gri kurt optimize edici." IEEE Access 8 (2020): 107635-107649.
- [38] Jiao, Y., & Du, P. "Sınıflandırmalar için makine öğrenimi tabanlı biyoinformatik tahmincilerin değerlendirilmesinde performans ölçütleri". Kantitatif Biyoloji, 4(4), pp.320-330. 2016.

Marwa M. Eid, 2015 yılında Mısır'daki Mansoura Üniversitesi Mühendislik Fakültesi'nden elektronik ve iletişim mühendisliği alanında doktora derecesini almıştır. Eid, 2011 yılından bu yana Delta Mühendislik ve Teknoloji Yüksek Enstitüsü'nde Yardımcı Doçent olarak görev yapmaktadır ve şu anki araştırma alanları arasında görüntü işleme, şifreleme, kablosuz iletişim sistemleri ve sahada programlanabilir kapı dizisi (FPGA) uygulamaları.



Yasser H. Elawady, MISR Mühendislik ve Teknoloji Yüksek Enstitüsü Bilgisayar Mühendisliği Bölümü'nde Yardımcı Doçent olarak görev yapmaktadır ve doktorasını Mısır Mansoura Üniversitesi Bilgisayar ve İletişim Fakültesi'nden almıştır. Yüksek lisansını 2003 yılında Mansoura Üniversitesi, Mansoura, Mısır, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü'nden almıştır. İlgili alanları arasında Uzaktan Erişim bulunmaktadır, FPGA programlama, Donanım Tasarımı, bilgisayar mimarisi ve organizasyonu ve Ağ oluşturma.



